SPRINT 3
INGREDION

GRUPO 9

Amanda Fragnan
Iolanda Manzali
Jônatas Gomes
Murilo Nasser
Pedro Sousa

METODOLOGIA

Os dados históricos utilizados no projeto foram coletados a partir de bases públicas oficiais e confiáveis, fundamentais para análises no contexto agrícola. Foram utilizadas as seguintes fontes:

- IBGE - SIDRA: Dados de produtividade agrícola por cultura e por município.
- INMET: Dados meteorológicos históricos, incluindo precipitação, temperatura, radiação solar, umidade e vento.
- CONAB: Custos de produção agrícola históricos, disponibilizados em planilhas por cultura e safra.
- SATVEG - Embrapa: Dados de NDVI (Índice de Vegetação por Diferencial Normalizado) calculados a partir de imagens de satélite.

A coleta foi realizada através do download manual de dados CSV (para INMET, CONAB e IBGE) e extração dos dados NDVI via a plataforma SATVEG. Todos esses dados foram carregados na nuvem Oracle utilizando APIs REST, e posteriormente integrados e processados na aplicação desenvolvida em Streamlit.

TÉCNICAS ESTATÍSTICAS APLICADAS

Foi aplicada análise de correlação utilizando a Matriz de Correlação de Pearson, que mede a força e a direção da relação linear entre variáveis numéricas. Isso permitiu entender como variáveis como NDVI, precipitação, temperatura, pressão atmosférica e produtividade agrícola se relacionam entre si.

Observou-se uma correlação positiva entre NDVI e produtividade agrícola, indicando que maiores índices de vegetação estão associados a melhores rendimentos.

Para a modelagem preditiva, foram aplicadas diversas técnicas de regressão supervisionada:

- Regressão Linear
- Árvore de Decisão
- Random Forest
- Gradient Boosting
- Support Vector Regression (SVR)
- K-Nearest Neighbors (KNN)
- Ridge, Lasso e Elastic Net (técnicas de regressão regularizada)

Esses modelos foram ajustados utilizando GridSearchCV, uma técnica de busca em grade que seleciona os melhores hiperparâmetros baseados no menor erro quadrático médio (RMSE).

MODELOS TREINADOS

Após o processo de treinamento e avaliação dos modelos, os resultados indicaram diferenças significativas no desempenho entre os algoritmos testados.

A métrica utilizada para avaliação foi o Root Mean Squared Error (RMSE), que permite mensurar o erro médio das previsões em relação aos valores reais.

O modelo que apresentou o melhor desempenho foi o Gradient Boosting, com um RMSE de 1963.80, evidenciando sua capacidade de capturar relações não lineares e interações entre as variáveis do conjunto de dados. Este resultado reforça a eficácia dos métodos baseados em ensembles para problemas de previsão com dados complexos, como os meteorológicos.

Outros modelos baseados em árvores também obtiveram resultados satisfatórios, como o Random Forest (RMSE: 2582.24) e a Árvore de Decisão (RMSE: 2968.85), embora com desempenho inferior ao Gradient Boosting. Isso demonstra que os modelos de árvore são capazes de lidar bem com dados que apresentam padrões não lineares.

Por outro lado, os modelos lineares, como Regressão Linear, Ridge, Lasso e Elastic Net, apresentaram RMSEs na faixa de 5036 a 5898, indicando limitações na modelagem da variabilidade dos dados. Esses modelos não foram suficientes para capturar a complexidade das relações presentes nos dados meteorológicos.

MODELOS TREINADOS

Os modelos baseados em distância, como o KNN, tiveram desempenho insatisfatório (RMSE: 16792.52), possivelmente devido à alta dimensionalidade dos dados ou à falta de uma densidade suficiente de pontos próximos, problema conhecido como curse of dimensionality. A Máquina de Vetores de Suporte (SVM) também obteve um desempenho muito inferior (RMSE: 25359.60), o que pode estar relacionado ao fato de que modelos baseados nesses kernels não ideais para os dados em questão.

Os resultados obtidos reforçam que o problema apresenta características não lineares, nas quais métodos de ensemble, especialmente o Gradient Boosting, são mais eficientes. A diferença significativa de desempenho entre modelos lineares e não lineares evidencia a necessidade de técnicas mais robustas para tratar a complexidade dos dados meteorológicos.
Diante disso, optou-se por adotar o Gradient Boosting como modelo final para a etapa de previsão, considerando seu menor erro e maior capacidade de generalização frente aos demais modelos testado

RESULTADOS

Os resultados confirmam a forte dependência da produtividade agrícola em relação às condições climáticas e ao desenvolvimento vegetativo, representado pelo NDVI. A análise de correlação revelou que, além do NDVI, variáveis como precipitação e temperatura são fundamentais para estimativas precisas de produtividade.

Os valores ausentes nas Tabelas do INMET podem comprometer a qualidade das análises e modelagens subsequentes.

Na tentativa de minimizar distorções foi adotada a imputação pela média temporal dos valores disponíveis para preencher os dados ausentes. Por exemplo, para os valores faltantes do parâmetro pressao_atmosferica da data 05/01/2016 foi feita a média temporal dos dia 05/01 dos outros anos com valores disponíveis.

A imputação pela média temporal pode não capturar variações específicas ou eventos extremos, o que deve ser considerado na interpretação dos resultados.

Observou-se também tempo de latência significativo em três fases cruciais: carregamento de dados da API Oracle, execução da Análise Exploratória de Dados (EDA) e treinamento dos modelos de Machine Learning.

Sugestões de Melhorias:

- Incorporar variáveis relacionadas ao tipo de solo e cobertura vegetal.
- Integrar dados de sensoriamento remoto de outras fontes
- Refinar a granularidade dos dados meteorológicos, utilizando estações mais próximas dos pontos de interesse.

REFERÊNCIAS DAS BASES PÚBLICAS UTILIZADAS

iBGE - SIDRA
https://sidra.ibge.gov.br/tabela/839
https://sidra.ibge.gov.br/tabela/5457

INMET - Instituto Nacional de Meteorologia
https://portal.inmet.gov.br/dadoshistoricos

CONAB - Companhia Nacional de Abastecimento
https://www.conab.gov.br/info-agro/custos-de-producao/planilhas-de-custo-de-producao

SATVEG - Plataforma de Sensoriamento Remoto da Embrapa
https://www.satveg.cnptia.embrapa.br